

۱. مجموعه داده اول

مجموعه داده اول در سال ۲۰۱۶ توسط عزت و همکاران [۱] معرفی شده است. اغلب روش‌های جدید پیش‌بینی تعاملات دارو-هدف، با استفاده از این مجموعه داده، روش خود را ارزیابی و نتایج را گزارش کرده‌اند [۴-۱]. این مجموعه داده شامل سه فایل متنی تعاملات دارو-هدف، ویژگی‌های داروها و ویژگی‌های اهداف می‌باشد و تمام داده‌های موجود در این مجموعه داده، از نوع عددی هستند.

مجموعه داده اول در دو قسمت توضیح داده می‌شود؛ در قسمت اول، اطلاعاتی درباره تعاملات دارو-هدف و در قسمت دوم اطلاعات دارو و هدفی که مورد استفاده قرار گرفته شده است و نحوه نمایش آن‌ها به صورت بردارهای ویژگی، تشریح می‌شود.

۱-۱. اطلاعات تعاملات دارو-هدف

عناصر فایل تعاملات دارو-هدف از اعداد صفر و یک تشکیل شده است؛ این فایل به صورت یک ماتریس دوبعدی $Y \in \mathbb{R}^{n \times m}$ دارای n سطر دارو و m ستون پروتئین هدف می‌باشد؛ به طوریکه اگر $Y_{ij} = 1$ باشد، دارو d_i با هدف t_j تعامل دارد و در غیر اینصورت $Y_{ij} = 0$ می‌باشد. به عبارت دیگر عدد یک نشان‌دهنده وجود تعامل و عدد صفر نشان‌دهنده عدم تعامل بین دارو d_i که در سطر ماتریس و هدف t_j که در ستون ماتریس قرار گرفته است، می‌باشد. تعاملات موجود در این مجموعه داده از پایگاه داده DrugBank [5, 6] بدست می‌آید. در این مجموعه داده ۵۸۷۷ دارو، ۳۳۴۸ پروتئین هدف و ۱۲۶۷۴ تعامل شناخته شده وجود دارد.

۱-۲. اطلاعات داروها و اهداف

ویژگی‌های داروهای موجود در این مجموعه داده با استفاده از کتابخانه Rcpi [۷] محاسبه می‌شود. نمونه‌هایی از ویژگی‌های داروها شامل توصیف‌کننده‌های constitutional، توپولوژیکی^۱، geometrical و دیگر خصوصیات مولکولی می‌باشد [۱]. ویژگی‌هایی از اهداف که بتواند خواص پروتئین‌های مختلف را به طور جامع توصیف کنند از توالی ژنومی پروتئین‌ها با استفاده از وب سرور PROFEAT [۸] تولید می‌شود؛ نمونه‌هایی از ویژگی‌های اهداف شامل توصیف‌کننده‌های مربوط به ترکیب اسید آمینه^۲، dipeptide composition، همبستگی، amphiphilic pseudo-amino acid و چند ویژگی دیگر است که در وب سرور PROFEAT قابل مشاهده می‌باشد [۱].

¹ Topological

² Amino acid composition

فایل ویژگی‌های داروها به صورت ماتریس $D \in \mathbb{R}^{n \times f}$ و ویژگی‌های اهداف به شکل ماتریس $T \in \mathbb{R}^{m \times g}$ می‌باشد که f و g تعداد ویژگی‌های داروها و اهداف است. عناصر تشکیل دهنده این ماتریس‌ها اعدادی هستند که مقادیر توصیف کننده‌های ملکولی داروها و اهداف را نشان می‌دهند. مقادیر ویژگی‌های داروها و اهداف اعدادی اعشاری هستند که همه آن‌ها برای اجتناب از سوگیری ویژگی‌ها با مقادیر بزرگ با استفاده از روش نرمال سازی Min-Max در بازه $[0, 1]$ قرار گرفته‌اند. در این مجموعه داده هر دارو و هدف به ترتیب با یک بردار ویژگی 193 بعدی و 1290 بعدی نشان داده می‌شود؛ به این صورت که هر دارو به شکل $d = [d_1, d_2, \dots, d_p]$ و هر هدف به صورت $t = [t_1, t_2, \dots, t_a]$ نمایش داده می‌شود. جزئیات این مجموعه داده در جدول ۱ آورده شده است.

جدول ۱. جزئیات مجموعه داده اول

تعداد داروها	تعداد اهداف	تعداد تعاملات
۵۸۷۷	۳۳۴۸	۱۲۶۷۴

تشکیل بردارهای دارو-هدف برای استفاده در مدل یادگیری ماشین به صورت $[d_1, d_2, \dots, d_p, t_1, t_2, \dots, t_q, I]$ می‌باشد که برچسب I یک عدد باینری است و نشان دهنده وجود یا عدم وجود تعامل بین دارو و هدف موجود در بردار می‌باشد. برچسب I از طریق ماتریس تعاملات دارو-هدف مشخص می‌شود. شکل ۱ و ۲ به ترتیب نمایی از فایل تعاملات دارو-هدف و فایل ویژگی‌های داروها می‌باشد.

[illegible]

شکل ۱. نمایی از فایل تعاملات دارو-هدف

The file size (6.48 MB) exceeds the configured limit (2.56 MB). Code insight features are not available.																										
1	0.74017	0.01967	0.24839	0.23409	0.23077	0	0	0	0	0	0.23077	0	0.66667	0.2	0.11111	0	0.33333	0	0	0.2175	0.10824	0.822	✓			
2	0.77503	0.0099534	0.20324	0.18898	0.17949	0.16667	0.5	0	0.16667	0.14286	0	0.20513	0	0	0.33333	0	0	0	0	0.17125	0.088254					
3	0.77162	0.010758	0.29128	0.26601	0.25641	0.16667	0	0	0	0.25641	0	0	0.33333	0.2	0	0.16667	0	0	0.24125	0.10624	0.82					
4	0.84958	0.00017337	0.25819	0.25141	0.15385	0	0	0	0	0.17949	0	0	0.4	0	0	0.4	0.24375	0.089449	0.82397	0.82						
5	0.76321	0.01288	0.20109	0.18744	0.20513	0	0.5	0	0.33333	0.14286	0	0.23077	0	0	0.33333	0	0.11111	0	0	0.17	0.084837					
6	0.79337	0.0061565	0.21689	0.18973	0.17949	0	0	0	0.33333	0	0.17949	0	0	0	0.11111	0.16667	0.25	0	0.17	0.069826						
7	0.83887	0.00065599	0.043929	0.035165	0	0	0	0	0	0	0	0	0	0	0	0	0.03125	0.029281	0.92733	0.85						
8	0.83527	0.00088729	0.26454	0.25528	0	0	0	0	0	0	0	0	0	0	0	0.22625	0.020701	0.96091	0.83373	0.17						
9	0.82023	0.0022332	0.086367	0.073563	0.025641	0	0	0	0	0.14286	0.051282	0	0	0	0	0	0	0	0	0.0675	0.04					
10	0.82983	0.0013039	0.030515	0.024233	0.025641	0	0	0	0	0.025641	0	0	0.025641	0	0	0	0	0	0.02375	0.014919						
11	0.8071	0.003908	0.070662	0.066079	0.025641	0	0	0	0	0	0.025641	0	0	0	0	0	1	0	0	0.06125	0.040021					
12	0.85476	5.1187e-005	0.014376	0.010469	0	0	0	0	0	0	0	0	0	0	0	0	0.01125	0.014746	0.97967	0.82						
13	0.86246	3.198e-006	0.039448	0.029701	0.025641	0	0	0	0	0.025641	0	0	0.025641	0	0	0	0	0	0.0275	0.010025						
14	0.84538	0.00032589	0.042468	0.04196	0	0	0	0	0	0	0	0	0	0	0	0.03875	0.01839	0.95523	0.84023	0.17						
15	0.84128	0.00052035	0.023237	0.022464	0	0	0	0	0	0	0	0	0	0	0	0.025	0.0084866	0.97708	0.83							
16	0.82662	0.0015871	0.025917	0.027001	0.025641	0	0	0	0	0.025641	0	0	0.025641	0	0	0.11111	0	0	0.02875	0.01						
17	0.83371	0.00099868	0.029167	0.029726	0.025641	0.16667	0	0	0	0.025641	0	0	0	0	0	0	0	0	0.03125	0.01						
18	0.83897	0.00064999	0.029135	0.023293	0	0	0	0	0.026036	0	0	0	0	0	0	0.02375	0.026036	0.97091	0.81							
19	0.81821	0.0024606	0.043922	0.046372	0	0	0	0	0	0	0	0	0	0	0	0.04875	0.0078048	0.98199	0.83							
20	0.84405	0.00038376	0.021203	0.017483	0.025641	0	0.5	0	0	0.025641	0	0	0	0	0	0	0	0	0.01875	0.018201						
21	0.83021	0.001272	0.023591	0.023169	0.025641	0	0	0	0	0	0.025641	0	0	0	0	0	0	0	0.025	0.011076						
22	0.83553	0.0008695	0.023706	0.02251	0.025641	0	0	0	0.14286	0.025641	0	0	0	0	0	0	0	0	0.02375	0.015912						
23	0.81864	0.0024119	0.058498	0.049273	0	0	0	0	0	0	0	0	0	0	0	0.045	0.046482	0.8929	0.84							
24	0.8597	2.0128e-006	0.064148	0.063653	0	0	0	0	0	0	0	0	0	0	0	0.06125	0.0083392	0.9806	0.83							

شکل ۲. نمایی از فایل ویژگی‌های دارو

- [١] A. Ezzat, M. Wu, X.-L. Li, and C.-K. Kwoh, "Drug-target interaction prediction via class imbalance-aware ensemble learning," *BMC bioinformatics*, vol. 17, no. 19, p. 509, 2016.
- [٢] A. Sharma and R. Rani, "BE-DTI': ensemble framework for drug target interaction prediction using dimensionality reduction and active learning," *Computer methods and programs in biomedicine*, vol. 165, pp. 151-162, 2018.
- [٣] A. Ezzat, M. Wu, X.-L. Li, and C.-K. Kwoh, "Computational prediction of drug-target interactions using chemogenomic approaches: an empirical survey," *Brief Bioinform*, vol. 8, 2018.
- [٤] A. Ezzat, M. Wu, X.-L. Li, and C.-K. Kwoh, "Drug-target interaction prediction using ensemble learning and dimensionality reduction," *Methods*, vol. 129, pp. 81-88, 2017.
- [٥] C. Knox *et al.*, "DrugBank 3.0: a comprehensive resource for 'omics' research on drugs," *Nucleic acids research*, vol. 39, no. suppl_1, pp. D1035-D1041, 2010.
- [٦] D. S. Wishart *et al.*, "DrugBank: a comprehensive resource for in silico drug discovery and exploration," *Nucleic acids research*, vol. 34, no. suppl_1, pp. D668-D672, 2006.
- [٧] D.-S. Cao, N. Xiao, Q.-S. Xu, and A. F. Chen, "Rcpi: R/Bioconductor package to generate various descriptors of proteins, compounds and their interactions," *Bioinformatics*, vol. 31, no. 2, pp. 279-281, 2014.
- [٨] Z.-R. Li, H. H. Lin, L. Han, L. Jiang, X. Chen, and Y. Z. Chen, "PROFEAT: a web server for computing structural and physicochemical features of proteins and peptides from amino acid sequence," *Nucleic Acids Research*, vol. 34, no. suppl_2, pp. W32-W37, 2006.